

LZW: Wörterbuchverfahren nach Lempel-Ziv-Welch

Wörterbuchverfahren hinterlegen wiederkehrende Zeichenfolgen in einem Wörterbuch. Kommen diese Zeichenfolgen dann im zu komprimierenden Text vor, reicht ein Verweis auf diesen Eintrag. Das LZW-Verfahren arbeitet dabei mit einem dynamischen Wörterbuch, welches direkt während der Kompression selbst erzeugt wird und damit keinen zusätzlichen Speicherplatz benötigt.

Um jedoch Platz für das Wörterbuch neben den normalen (ASCII-)Zeichen zu schaffen, reichen 8 Bit nicht mehr aus. Für gewöhnlich werden hierfür 12 Bit für jedes Zeichen bzw. Wörterbucheintrag verwendet. Das Wörterbuch kann also maximal $2^{12} = 4096$ Zeichen und Zeichenkombinationen beinhalten, wovon die ersten 256 Einträge fest mit den ASCII-Zeichen vorbelegt sind.

Die Codierung verläuft nach folgendem Algorithmus:

1. Lies eine möglichst lange Zeichenkette ein, die bereits im Wörterbuch steht
 - Zu Beginn ist das jeweils nur ein einzelnes Zeichen!
2. Schreibe den 12-Bit-Code des gefundenen Eintrags in die Ausgabe.
3. Lege aus der eben gefundenen Zeichenkette und dem nachfolgenden Zeichen einen neuen Wörterbucheintrag mit der nächst möglichen Codierung an.
4. Ggf. Wird das letzte Byte der Ausgabe mit 0 aufgefüllt

Beispiel: „BABAABBA“ soll codiert werden. Das Wörterbuch ist am Anfang im Bereich von 000_{16} bis $0FF_{16}$ mit den ASCII-Zeichen befüllt.

Noch zu bearbeitende Zeichenkette	Gefundener Eintrag	Ausgabe 12Bit	Neuer Wörterbucheintrag
B AABAABBA	B ← 042_{16}	042_{16}	BA → 100_{16}
A ABAABBA	A ← 041_{16}	041_{16}	AB → 101_{16}
BA AABBA	BA ← 100_{16}	100_{16}	BAA → 102_{16}
AB BAA	AB ← 101_{16}	101_{16}	ABB → 103_{16}
BAA	BAA ← 102_{16}	102_{16}	

Die Zeichenfolge wird also folgendermaßen codiert: 042041100101102_{16} , das entspricht 7,5 Bytes, was mit einer 0 zu 8 vollständigen Bytes aufgefüllt wird.

Aufgabe 1:

Codiere den Text „ABABCABCDABCD“ und vergleiche die codierte und die uncodierte Länge miteinander.

Bei der Decodierung werden 12-Bit-Blöcke eingelesen. Das Wörterbuch wird aber mit Einträgen befüllt die aus dem ersten Zeichen des aktuellen Eintrag und dem vorangehenden Eintrag bestehen.

Beispiel: 042041100101102

Aktueller 12Bit-Block	Gefundener Eintrag (erster Buchstabe)	Neuer Wörterbucheintrag	Ausgabe
042	B (B)		B
041	A (A)	BA = 100_{16}	A
100	BA (B)	AB = 101_{16}	BA
101	AB (A)	BAA = 102_{16}	AB
102	BAA (B)	ABB = 103_{16}	BAA

Daraus wird also der Text „BABAABBAA“

Aufgabe 2:

a) Decodiere den Code: „058059060101100103“

b) Versuche, den Code „042041100101041104“ zu decodieren. Welches Problem ergibt sich dabei?